

Atividade Avaliativa 1 - Tratamento de dados

In [5]: `! pip install pandas`

Requirement already satisfied: pandas in .\.venv\Lib\site-packages (3.0.5)
 Requirement already satisfied: numpy>=2.3.3 in .\.venv\Lib\site-packages (from pandas) (2.5.3)
 Requirement already satisfied: python-dateutil>=2.8.2 in .\.venv\Lib\site-packages (from pandas) (2.9.0.post0)
 Requirement already satisfied: tzdata in .\.venv\Lib\site-packages (from pandas) (2026.3)
 Requirement already satisfied: six>=1.5 in .\.venv\Lib\site-packages (from python-dateutil>=2.8.2->pandas) (1.17.0)
 [notice] A new release of pip is available: 26.0.1 -> 26.2.1
 [notice] To update, run: python.exe -m pip install --upgrade pip

In [35]: `import pandas as pd
import numpy as np`

In [3]: `df = pd.read_csv("base_vendas.csv")

df.head()`

Out[3]:

	id_venda	cliente	cidade	categoria	produto	quantidade	preco_unitario	forma
0	10001	Karen	São Paulo	Eletrônicos	Monitor	5.0	1218.34	
1	10002	Thiago	Curitiba	Casa	Jogo de Cama	6.0	238.88	
2	10003	Daniela	Belo Horizonte	Casa	Panela	-1.0	NaN	
3	10004	Nicolas	Brasília	Casa	Panela	1.0	156.45	
4	10005	Isabela	Curitiba	eletrônicos	Monitor	5.0	1255.33	

In [47]: `df.shape`

Out[47]: (600, 11)

In [48]: `df.info()`

```

<class 'pandas.DataFrame'>
RangeIndex: 600 entries, 0 to 599
Data columns (total 11 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   id_venda              600 non-null   int64  
 1   cliente               600 non-null   str     
 2   cidade               600 non-null   string  
 3   categoria             600 non-null   string  
 4   produto              600 non-null   str     
 5   quantidade            600 non-null   float64 
 6   preco_unitario        600 non-null   float64 
 7   forma_pagamento      600 non-null   string  
 8   status               600 non-null   string  
 9   valor_total           600 non-null   float64 
10   faixa_venda           600 non-null   category
dtypes: category(1), float64(3), int64(1), str(2), string(4)
memory usage: 47.7 KB

```

In [49]: `df.describe()`

Out[49]:

	id_venda	quantidade	preco_unitario	valor_total
count	600.000000	600.000000	600.000000	600.000000
mean	10300.500000	4.088333	539.569233	2284.847267
std	173.349358	2.014272	848.558599	4108.489779
min	10001.000000	1.000000	53.320000	53.660000
25%	10150.750000	2.000000	108.060000	355.035000
50%	10300.500000	4.000000	224.020000	855.090000
75%	10450.250000	6.000000	333.847500	1712.287500
max	10600.000000	7.000000	3973.020000	26966.170000

In [50]: `print(df.columns)`

```

Index(['id_venda', 'cliente', 'cidade', 'categoria', 'produto', 'quantidade',
      'preco_unitario', 'forma_pagamento', 'status', 'valor_total',
      'faixa_venda'],
      dtype='str')

```

In [51]: `# 3. Estatísticas simples`

```

print("\nResumo estatístico:")
print(df.describe(include="all"))

```

Resumo estatístico:

	id_venda	cliente	cidade	categoria	produto	quantidade	\
count	600.000000	600	600	600	600	600.000000	
unique	NaN	24	8	6	25	NaN	
top	NaN	Karen	Curitiba	Eletrônicos	Notebook	NaN	
freq	NaN	37	100	133	33	NaN	
mean	10300.500000	NaN	NaN	NaN	NaN	4.088333	
std	173.349358	NaN	NaN	NaN	NaN	2.014272	
min	10001.000000	NaN	NaN	NaN	NaN	1.000000	
25%	10150.750000	NaN	NaN	NaN	NaN	2.000000	
50%	10300.500000	NaN	NaN	NaN	NaN	4.000000	
75%	10450.250000	NaN	NaN	NaN	NaN	6.000000	
max	10600.000000	NaN	NaN	NaN	NaN	7.000000	

	preco_unitario	forma_pagamento	status	valor_total	faixa_venda
count	600.000000	600	600	600.000000	600
unique	NaN	5	3	NaN	3
top	NaN	Cartão	Concluída	NaN	Média
freq	NaN	161	465	NaN	214
mean	539.569233	NaN	NaN	2284.847267	NaN
std	848.558599	NaN	NaN	4108.489779	NaN
min	53.320000	NaN	NaN	53.660000	NaN
25%	108.060000	NaN	NaN	355.035000	NaN
50%	224.020000	NaN	NaN	855.090000	NaN
75%	333.847500	NaN	NaN	1712.287500	NaN
max	3973.020000	NaN	NaN	26966.170000	NaN

```
In [52]: print("\nMédia do preço unitário:", df["preco_unitario"].mean())
print("Mediana do preço unitário:", df["preco_unitario"].median())
print("Média da quantidade:", df["quantidade"].mean())
```

Média do preço unitário: 539.5692333333334

Mediana do preço unitário: 224.02

Média da quantidade: 4.088333333333333

```
In [53]: # 4. Qualidade: nulos e duplicados

print("\nValores nulos por coluna:")
print(df.isna().sum())

print("\nRegistros duplicados:", df.duplicated().sum())
```

Valores nulos por coluna:

```
id_venda      0
cliente       0
cidade        0
categoria     0
produto       0
quantidade    0
preco_unitario 0
forma_pagamento 0
status        0
valor_total   0
faixa_venda   0
dtype: int64
```

Registros duplicados: 0

```
In [54]: # 5. Padronização de categorias

df["cidade"] = df["cidade"].astype("string").str.strip().str.lower()
```

```

df["categoria"] = df["categoria"].astype("string").str.strip().str.lower()
df["forma_pagamento"] = df["forma_pagamento"].astype("string").str.strip().str.l
df["status"] = df["status"].astype("string").str.strip().str.lower()

df["cidade"] = df["cidade"].replace({
    "são paulo":"São Paulo", "sao paulo":"São Paulo",
    "rio de janeiro":"Rio de Janeiro",
    "belo horizonte":"Belo Horizonte",
    "curitiba":"Curitiba", "porto alegre":"Porto Alegre",
    "salvador":"Salvador", "brasília":"Brasília", "brasilíia":"Brasília"
})

df["categoria"] = df["categoria"].replace({
    "eletrônicos":"Eletrônicos", "eletronicos":"Eletrônicos",
    "roupas":"Roupas", "casa":"Casa",
    "esportes":"Esportes", "livros":"Livros"
})

df["forma_pagamento"] = df["forma_pagamento"].replace({
    "cartão":"Cartão", "cartao":"Cartão",
    "pix":"PIX", "boleto":"Boleto", "dinheiro":"Dinheiro"
})

df["status"] = df["status"].replace({
    "concluída":"Concluída", "concluida":"Concluída",
    "cancelada":"Cancelada", "pendente":"Pendente"
})

```

In [55]: df.head()

Out[55]:

	id_venda	cliente	cidade	categoria	produto	quantidade	preco_unitario	forma
0	10001	Karen	São Paulo	Eletrônicos	Monitor	5.0	1218.34	
1	10002	Thiago	Curitiba	Casa	Jogo de Cama	6.0	238.88	
2	10003	Daniela	Belo Horizonte	Casa	Panela	4.0	224.02	n
3	10004	Nicolas	Brasília	Casa	Panela	1.0	156.45	
4	10005	Isabela	Curitiba	Eletrônicos	Monitor	5.0	1255.33	

In [56]: *# 6. Tratamento de valores nulos*

```

for col in ["cidade", "categoria", "forma_pagamento"]:
    df[col] = df[col].fillna("Não informado")

df["quantidade"] = pd.to_numeric(df["quantidade"], errors="coerce")
df["preco_unitario"] = pd.to_numeric(df["preco_unitario"], errors="coerce")

# Valores <= 0 são considerados inválidos

df.loc[df["quantidade"] <= 0, "quantidade"] = np.nan
df.loc[df["preco_unitario"] <= 0, "preco_unitario"] = np.nan

# Substituição pela mediana

```

```
df["quantidade"] = df["quantidade"].fillna(df["quantidade"].median())
df["preco_unitario"] = df["preco_unitario"].fillna(df["preco_unitario"].median())
```

In [57]: df.head()

Out[57]:

	id_venda	cliente	cidade	categoria	produto	quantidade	preco_unitario	forma
0	10001	Karen	São Paulo	Eletrônicos	Monitor	5.0	1218.34	
1	10002	Thiago	Curitiba	Casa	Jogo de Cama	6.0	238.88	
2	10003	Daniela	Belo Horizonte	Casa	Panela	4.0	224.02	n
3	10004	Nicolas	Brasília	Casa	Panela	1.0	156.45	
4	10005	Isabela	Curitiba	Eletrônicos	Monitor	5.0	1255.33	

In [58]:

```
# 7. Criação de novas colunas

df["valor_total"] = df["quantidade"] * df["preco_unitario"]

df["faixa_venda"] = pd.cut(
    df["valor_total"],
    bins=[-np.inf, 500, 1500, np.inf],
    labels=["Baixa", "Média", "Alta"]
)
```

In [59]: df.head()

Out[59]:

	id_venda	cliente	cidade	categoria	produto	quantidade	preco_unitario	forma
0	10001	Karen	São Paulo	Eletrônicos	Monitor	5.0	1218.34	
1	10002	Thiago	Curitiba	Casa	Jogo de Cama	6.0	238.88	
2	10003	Daniela	Belo Horizonte	Casa	Panela	4.0	224.02	n
3	10004	Nicolas	Brasília	Casa	Panela	1.0	156.45	
4	10005	Isabela	Curitiba	Eletrônicos	Monitor	5.0	1255.33	

In [60]:

```
# 8. Remoção de duplicidades pelo identificador

df = df.drop_duplicates(subset=["id_venda"], keep="first").reset_index(drop=True)
```

In [61]:

```
# 9. Agrupamentos

print("\nFaturamento por categoria:")
print(df.groupby("categoria")["valor_total"].sum().sort_values(ascending=False))

print("\nFaturamento por cidade:")
print(df.groupby("cidade")["valor_total"].sum().sort_values(ascending=False))
```

```
print("\nQuantidade de vendas por faixa:")
print(df["faixa_venda"].value_counts())
```

Faturamento por categoria:

```
categoria
Eletrônicos      854516.70
Esportes         196382.69
Casa             148631.09
Roupas           104857.73
Livros           35897.03
não informado    30623.12
Name: valor_total, dtype: float64
```

Faturamento por cidade:

```
cidade
Belo Horizonte   241930.98
Rio de Janeiro   241207.43
Porto Alegre     216990.94
Curitiba        186024.23
Salvador         175394.00
São Paulo        158533.73
Brasília         124020.18
não informado    26806.87
Name: valor_total, dtype: float64
```

Quantidade de vendas por faixa:

```
faixa_venda
Média      214
Baixa      206
Alta       180
Name: count, dtype: int64
```

In [62]: *# 10. Resultado final*

```
print("\nDimensões após tratamento:", df.shape)
print("\nNulos após tratamento:")
print(df.isna().sum())
print("\nPrimeiras linhas:")
print(df.head())
```

Dimensões após tratamento: (600, 11)

Nulos após tratamento:

```
id_venda      0
cliente       0
cidade        0
categoria     0
produto       0
quantidade    0
preco_unitario 0
forma_pagamento 0
status        0
valor_total   0
faixa_venda   0
dtype: int64
```

Primeiras linhas:

	id_venda	cliente	cidade	categoria	produto	quantidade	\
0	10001	Karen	São Paulo	Eletrônicos	Monitor	5.0	
1	10002	Thiago	Curitiba	Casa	Jogo de Cama	6.0	
2	10003	Daniela	Belo Horizonte	Casa	Panela	4.0	
3	10004	Nicolas	Brasília	Casa	Panela	1.0	
4	10005	Isabela	Curitiba	Eletrônicos	Monitor	5.0	

	preco_unitario	forma_pagamento	status	valor_total	faixa_venda
0	1218.34	Boleto	Concluída	6091.70	Alta
1	238.88	Cartão	Concluída	1433.28	Média
2	224.02	não informado	Concluída	896.08	Média
3	156.45	Dinheiro	Concluída	156.45	Baixa
4	1255.33	Dinheiro	Concluída	6276.65	Alta